Sistema borroso de control de tracción predictivo para motos de competición



Autor: Julián Samblás Caballero

Asignatura: Razonamiento Aproximado

Máster en Inteligencia Artificial

Contenido

1. Dominio y uso inteligente del sistema 3
2. Base de reglas imprecisas 4
3. Inferencia con representación no continua, relaciones borrosas y MPG 6
3.1. Universos y conjuntos discretos 6
3.2. Elección de parámetros 6
3.3. Construcción de la relación borrosa 7
3.4. Inferencia con el Modus Ponens Generalizado 8
3.5. Conclusión acerca de la elección de la implicación 9
4. Inferencia tipo Mamdani con números borrosos 9
4.1. Caso de estudio 9
4.2. Borrosificación 9
4.3. Evaluación de las reglas 10
4.4. Agregación y desborrosificación 10
5. Implementación en FuzzyCLIPS 11
5.1. Base de conocimiento 11
5.2. Base de hechos 13
5.3. Ejecución e inferencia tipo Mamdani 14
5.4. Conjunto borroso resultante 16
5.5. Desborrosificación 18
5.6. Comparación con el cálculo manual 18
Referencias 20
Anexo A. Script de representación en Python 20

1. Dominio y uso inteligente del sistema

Dominio: Electrónica de control de una moto de competición. El sistema es el núcleo de decisión de un control de tracción predictivo: a partir de la telemetría obtenida de la moto, decide cuánto par debe recortar la centralita al motor cuando el piloto acelera para evitar que la rueda trasera se descontrole al salir de una curva.

Objetivo: Un piloto en un circuito cuando abre gas la moto todavía está inclinada. En ese momento el neumático trasero tiene muy poca superficie de contacto, y un deslizamiento al salir de curva, que en recta sería inofensivo, podría provocar un "highside". El conocimiento que aplica un ingeniero de pista para ajustar esa intervención es intrínsecamente impreciso: "deslizamiento alto", "moto muy tumbada" o "recorte de par sueve", nunca deben ser umbrales exactos. La lógica borrosa permite formalizar este comportamiento sin destruir su naturaleza gradual.

El sistema recibirá dos variables de la telemetría y devolverá una acción de control:

Variable	Tipo	Universo
Deslizamiento de la rueda trasera	Entrada	0 – 20 %
Ángulo de inclinación	Entrada	0 – 60 grados
Recorte de par aplicado	Salida	0 – 100%

Uso: la idea es poder diseñar un tipo de control que sea predictivo (anticipar la pérdida de tracción) para así evitar que se den situaciones adversas en carrera. El sistema de reglas no espera a que el deslizamiento sea crítico, sino que lo pondera junto con la inclinación de modo que interviene en el momento adecuado únicamente. Es decir, interviene en el momento adecuado únicamente. Además, al tratarse de reglas lingüísticas, el sistema es explicable: el ingeniero puede leer por qué actuó la electrónica y ajustar una etiqueta.

Alcance: Micro-sistema de 5 reglas, dos entradas y una salida. Trabaja instante a instante, sin memoria del estado anterior.

Límites: no es un sistema embarcable tal cual. No contempla el desgaste ni la temperatura del neumático, la marcha engranada, el estado del firme ni la dinámica temporal del deslizamiento, ya que trabaja instante a instante sin memoria del estado anterior. Las funciones de pertenencia se han definido por criterio experto y no están ajustadas con telemetría real, lo que exigiría validación en banco antes de cualquier uso.

2. Base de reglas imprecisas

Las 5 reglas permiten razonamiento hacia delante: los hechos llegan de la telemetría (deslizamiento e inclinación), las reglas se disparan en la medida en que sus premisas se cumplen y producen la salida (recorte de par), que es el que se envía al actuador.

- R1: si el deslizamiento es alto y la inclinación es alta: el recorte de par es fuerte
- R2: si el deslizamiento es alto y la inclinación es baja: el recorte de par es medio
- R3: si el deslizamiento es medio y la inclinación es alta: el recorte es medio
- R4: si el deslizamiento es medio y la inclinación es media: el recorte de par es suave
- R5: si el deslizamiento es bajo: el recorte de par es nulo

Explicación física de las reglas: R1 es el caso crítico: rueda patinando con la moto tumbada, que es la receta del highside, y por eso la intervención es máxima. R2 describe el mismo deslizamiento, pero con la moto vertical, donde todavía es controlable la situación y forma parte del pilotaje. R3 y R4 cubren la zona intermedia y muestran cómo la inclinación modula la respuesta ante un mismo deslizamiento. R5 es incompleta en sus premisas: si la rueda no patina da igual lo tumbada que vaya la moto, así que la regla no tiene en cuenta la inclinación. Ya que siguiendo el enfoque de Mamdani, una base de reglas borrosa no tiene por qué cubrir todas las combinaciones posibles.

La matriz resultante tipo “Fuzzy Associative Memory”, queda de la siguiente manera, donde las casillas vacías son combinaciones no cubiertas:

Deslizamiento ↓ / Inclinación →	Baja	Media	Alta
bajo	nulo (R5)	nulo (R5)	nulo (R5)
medio	-	suave (R4)	Medio (R3)
alto	medio (R2)	-	Fuerte (R1)

Cada casilla indica el consecuente de la regla que se activa para esa combinación de etiquetas. Las dos casillas sin regla corresponden a combinaciones poco representativas: un deslizamiento medio con la moto vertical no requiere intervención apreciable, y un deslizamiento alto a inclinación media queda cubierto por la transición entre R1 y R2 gracias al solape de los conjuntos borrosos.

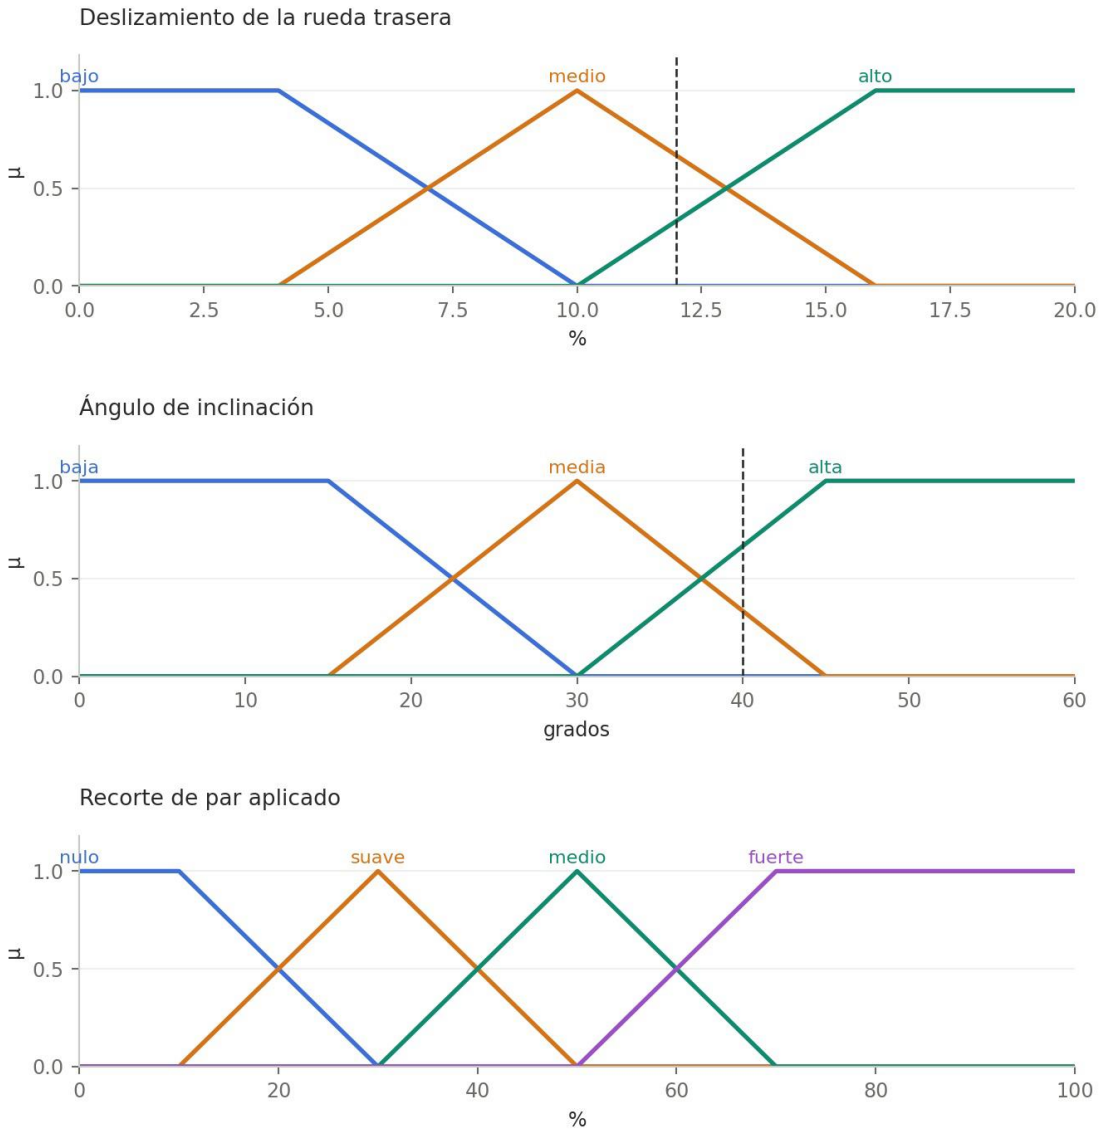
Variables lingüísticas:

Cada dominio se parte en tres o cuatro conjuntos borrosos, respetando el criterio de 7 ± 2 etiquetas por term-set:

Deslizamiento (0–20 %): bajo (0 1)(4 1)(10 0), medio (4 0)(10 1)(16 0), alto (10 0)(16 1)(20 1)

Inclinación (0–60°): baja (0 1)(15 1)(30 0), media (15 0)(30 1)(45 0), alta (30 0)(45 1)(60 1)

Recorte (0–100 %): nulo (0 1)(10 1)(30 0), suave (10 0)(30 1)(50 0), medio (30 0)(50 1)(70 0), fuerte (50 0)(70 1) (100 1)



Particiones borrosas de las tres variables. Las líneas discontinuas marcan el caso de estudio: deslizamiento 12 % e inclinación 40°.

Las funciones de pertenencia y los conjuntos resultantes se han representado gráficamente mediante un script propio en Python (anexo A). El desarrollo de la inferencia es analítico; el script se ha empleado para dibujar los conjuntos y para verificar numéricamente el valor del centro de gravedad, cuya integral se calcula por la regla del trapecio.

3. Inferencia con representación no continua, relaciones borrosas y MPG

Aquí el objetivo es hacer la inferencia paso a paso y a mano. Para poder representarlo en forma de tabla, primero discretizo los universos de las variables. Después convierto una de las reglas en una relación borrosa mediante una función de implicación, y por último aplico el Modus Ponens Generalizado con la regla composicional de inferencia para obtener la conclusión.

3.1. Universos y conjuntos discretos

Se discretizan los universos de la entrada y de la salida:

- X (deslizamiento) = {0, 5, 10, 15, 20} %
- Z (recorte de par) = {0, 25, 50, 75, 100} %

Con la notación del curso, los conjuntos implicados en la regla R5 son:

- bajo = 1/0 + 0,7/5 + 0,2/10
- nulo = 1/0 + 0,4/25

Se trabaja sobre R5 porque tiene una sola premisa y su relación es una matriz de 5 × 5, manejable a mano. Para las reglas de dos premisas el procedimiento es idéntico, pero la relación se define sobre X × Y × Z: primero se agregan las dos premisas con la t-norma mínimo y el resultado hace de antecedente único.

3.2. Elección de parámetros

Parámetro	Elección	Justificación
Función de implicación	Lukasiewicz, I(a,b) = min(1, 1 − a + b)	Es a la vez S-implicación y R-implicación, y es la que se emplea en los ejemplos de la asignatura.
t-norma (conjunción de premisas)	Mínimo	Criterio conservador: la conclusión no puede ser más fiable que la premisa más débil, lo que en seguridad activa es el comportamiento deseable
t-conorma (agregación de reglas)	Máximo	No interviene en este ejemplo, al trabajar con una

		única regla; se declara aquí porque es la que se usará en el apartado 4.
Composición	Max-min (sup-min)	La composición estándar de la regla composicional de inferencia

Descarté el producto como t-norma porque atenúa el resultado al combinar premisas (0,7 · 0,4 = 0,28, por debajo de ambas), mientras que el mínimo mantiene el valor de la premisa más débil, que es el criterio conservador que interesa en un sistema de seguridad.

3.3. Construcción de la relación borrosa

La regla R5 se representa como la relación R(x,z) = I(μ_bajo(x), μ_nulo(z)):

	z = 0	**z = 25**	**z = 50**	**z = 75**	**z = 100**
μ_nulo(z)	1,0	0,4	0,0	0,0	0,0
x = 0 (μ_bajo = 1,0)	1,0	0,4	0,0	0,0	0,0
x = 5 (μ_bajo = 0,7)	1,0	0,7	0,3	0,3	0,3
x = 10 (μ_bajo = 0,2)	1,0	1,0	0,8	0,8	0,8
x = 15 (μ_bajo = 0,0)	1,0	1,0	1,0	1,0	1,0
x = 20 (μ_bajo = 0,0)	1,0	1,0	1,0	1,0	1,0

Llama la atención que para x = 15 y x = 20 la relación vale 1 en todas las columnas. No es un error: en esos puntos el deslizamiento no pertenece en absoluto al conjunto "bajo", es decir, la premisa de la regla es falsa. En lógica clásica una implicación con premisa falsa es verdadera sea cual sea la conclusión, y la implicación de Lukasiewicz hereda ese comportamiento. Dicho de otro modo, la regla no dice nada sobre lo que hay que hacer cuando el deslizamiento no es bajo, y esa ausencia de información se representa con el valor 1.

3.4. Inferencia con el Modus Ponens Generalizado

Ahora aplico la regla a un hecho real. El sensor no observa exactamente "deslizamiento bajo", sino un deslizamiento algo mayor que bajo: la rueda empieza a moverse un poco, pero todavía lejos de lo que consideraríamos patinar. Ese hecho observado lo represento como un conjunto borroso desplazado respecto de la premisa de la regla:

$$A' = 0{,}8/0 + 1/5 + 0{,}3/10$$

Aquí es donde se ve la diferencia con la lógica clásica. Como A' no coincide con la premisa "bajo", el modus ponens clásico no podría disparar la regla: o encaja del todo o no concluye nada. El Modus Ponens Generalizado sí permite concluir, componiendo el hecho observado con la relación que construí antes:

$$B' = A' \circ R \text{ , es decir } \mu_{B'}(z) = \max_x \min[\, \mu_{A'}(x), \mu_R(x,z) \,]$$

Lo que hace esta fórmula es lo siguiente: para cada valor posible de la salida z, recorro todos los valores de entrada x, miro cuánto se parece el hecho a ese x y cuánto lo permite la regla, me quedo con el menor de los dos (el mínimo), y de todos esos caminos escojo el mejor (el máximo). En la práctica es recorrer la matriz columna por columna.

z	**x = 0**	**x = 5**	**x = 10**	**x = 15**	**x = 20**	**μ_B'(z)**
0	0,8	1,0	0,3	0,0	0,0	**1,0**
25	0,4	0,7	0,3	0,0	0,0	**0,7**
50	0,0	0,3	0,3	0,0	0,0	**0,3**
75	0,0	0,3	0,3	0,0	0,0	**0,3**
100	0,0	0,3	0,3	0,0	0,0	**0,3**

Cada celda es el mínimo entre μ_A'(x) y la casilla correspondiente de la relación R, y la última columna es el máximo de la fila. Por ejemplo, para z = 25: min(0,8 ; 0,4) = 0,4 , min(1 ; 0,7) = 0,7 , min(0,3 ; 1) = 0,3 , y los dos últimos valen 0 porque el hecho no llega hasta ahí. El máximo de esos valores es 0,7.

El resultado de la inferencia es:

$$B' = 1/0 + 0{,}7/25 + 0{,}3/50 + 0{,}3/75 + 0{,}3/100$$

La conclusión no es exactamente "recorte nulo", sino un conjunto **parecido** a nulo. Sigue concentrando la creencia en el 0 %, que es lo que dice la regla, pero se ha ensanchado hacia valores mayores porque el hecho observado también estaba

desplazado respecto de la premisa. Esto es justo lo que aporta el Modus Ponens Generalizado: la conclusión se deforma en la misma medida en que se deforma la premisa.

Si quisiera llevar esta conclusión a un actuador tendría que desborrosificarla. Con el centro de gravedad discreto:

recorte = Σ z·μ(z) / Σ μ(z) = (0·1 + 25·0,7 + 50·0,3 + 75·0,3 + 100·0,3) / (1 + 0,7 + 0,3 + 0,3 + 0,3) = 85 / 2,6 ≈ ***32,7 %***

3.5. Conclusión acerca de la elección de la implicación

Ese 32,7 % es demasiado alto para una conclusión que debería ser “no intervengas”. El motivo es que la implicación de Lukasiewicz, como toda S-implicación, deja una cola de plausibilidad: asigna valores no nulos a toda la zona alta del universo, porque lógicamente “si la premisa no se cumple, la implicación es verdadera”. Si se repite el mismo cálculo usando la implicación de Mamdani, I(a,b) = min(a,b), la relación queda acotada y el resultado es:

B’ = 0,8/0 + 0,4/25 *, con centro de gravedad ≈* ***8,3 %***

que es coherente con el sentido físico de la regla. Esta comparación justifica la decisión tomada en el apartado siguiente: para razonar sobre la implicación lógica interesa una implicación como la de Lukasiewicz, pero para controlar un actuador conviene la implicación de Mamdani, que recorta el consecuente en lugar de extenderlo. El propio material de la asignatura advierte de que elegir la función de implicación adecuada sigue siendo un problema abierto y depende del uso que se dé a la inferencia.

4. Inferencia tipo Mamdani con números borrosos

Ahora los universos se representan de forma continua, mediante números borrosos triangulares y trapezoidales (los definidos en el apartado 2), y se emplea el mecanismo de Mamdani completo: borrosificación, evaluación de reglas, agregación y desborrosificación.

4.1. Caso de estudio

Salida de una curva de velocidad media. La telemetría entrega dos valores nítidos:

deslizamiento *= 12 % e* ***inclinación*** *= 40 grados*

4.2. Borrosificación

Se proyectan los valores medidos sobre las etiquetas de cada variable:

Variable	Etiqueta	Grado de pertenencia
Deslizamiento = 12%	Bajo	0,00
	Medio	0,67
	Alto	0,33
Inclinación = 40º	Baja	0,00
	Media	0,33
	Alta	0,67

El valor medido pertenece simultáneamente a dos etiquetas, que es justo lo que la lógica clásica no puede representar.

4.3. Evaluación de las reglas

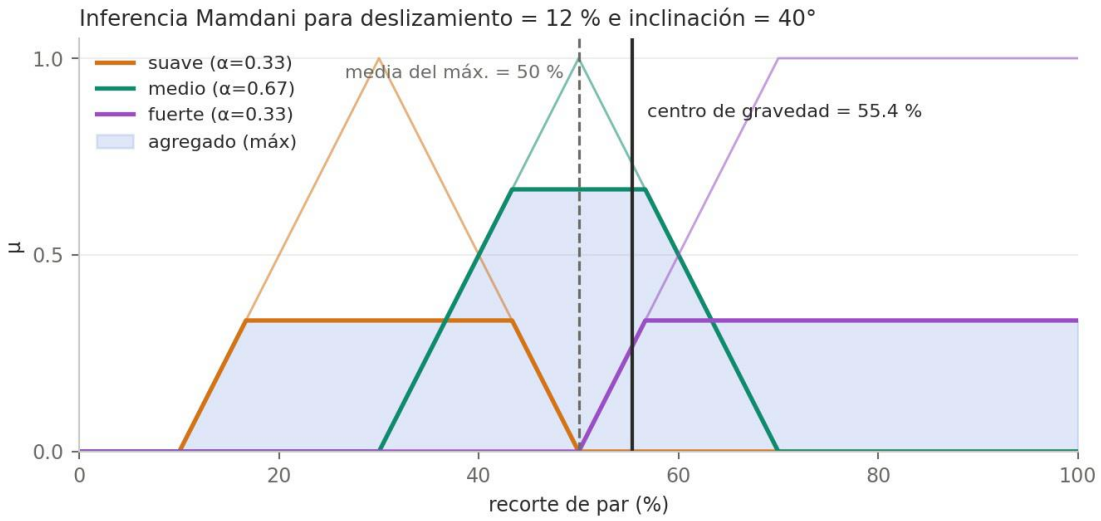
El grado de cumplimiento de cada regla es el mínimo de los grados de sus premisas:

Regla	Premisas	α = min	Consecuente
R1	alto (0,33) y alta (0,67)	0,33	Fuerte
R2	alto (0,33) y baja (0,00)	0,00	No se dispara
R3	medio (0,67) y alta (0,67)	0,67	Medio
R4	medio (0,67) y media (0,33)	0,33	Suave
R5	bajo (0,00)	0,00	No se dispara

Se disparan tres reglas. La dominante es R3, y R1 aporta un empujón hacia la zona alta: el sistema “sabe” que hay algo de riesgo de highside, aunque no sea el escenario más probable.

4.4. Agregación y desborrosificación

Cada consecuente se recorta a la altura de su α y los tres recortes se combinan con el máximo (unión):



Conjuntos consecuentes recortados a su grado de cumplimiento y conjunto agregado. La línea continua marca el centro de gravedad y la discontinua la media del máximo.

Sobre el conjunto agregado se aplican los dos criterios de desborrosificación vistos en clase:

Criterio	Resultado	Comentario
Media del máximo	50%	Solo atiende a la zona de máxima pertenencia, la aportada por R3. Ignora por completo la contribución de R1 y R4
Centro de gravedad	55,4%	Tiene en cuenta las tres reglas ponderadas por su aplicabilidad

Criterio elegido: centro de gravedad. Para un actuador que recorta par lo importante es que la acción de control sea **continua**: con la media del máximo, una variación mínima del deslizamiento puede hacer que el máximo salte de una etiqueta a otra y provoque un escalón en la entrega de potencia, que es exactamente lo que desestabiliza una moto inclinada. El centro de gravedad, además, recoge la aportación de R1: el resultado (55,4 %) es superior al centro de "medio" (50 %) precisamente porque existe un riesgo parcial de highside, y el sistema lo traduce en una intervención algo más agresiva. Su desventaja, el mayor coste de cálculo, es asumible en una ECU actual.

Lectura del resultado. Con la rueda deslizando un 12 % y la moto tumbada 40 grados, la electrónica recortaría en torno a un **55 % del par disponible**. Si el mismo deslizamiento se diera con la moto vertical, se dispararía R2 en lugar de R1 y R3, y el recorte bajaría notablemente: el sistema reproduce el comportamiento que se le pide a un control de tracción real.

5. Implementación en FuzzyCLIPS

Se adjuntan dos archivos: BC_MotoGP.clp (base de conocimientos: variables lingüísticas y reglas) y BH_MotoGP.clp (base de hechos: los valores medidos).

5.1. Base de conocimiento

A continuación, se presenta el código diseñado, dentro del archivo "BC_MotoGP.clp":

```
; ========================================================================
; BASE DE CONOCIMIENTOS (BC)  -  Control de traccion predictivo MotoGP
; Razonamiento Aproximado - Julian Samblas Caballero
; FuzzyCLIPS
; ========================================================================

; ------------------- VARIABLES LINGUISTICAS --------------------------

(deftemplate deslizamiento
        0 20
        (       (bajo    (0 1) (4 1) (10 0))
                (medio  (4 0) (10 1) (16 0))
                (alto     (10 0) (16 1) (20 1))      )
)

(deftemplate inclinacion
        0 60
        (       (baja    (0 1) (15 1) (30 0))
                (media  (15 0) (30 1) (45 0))
                (alta     (30 0) (45 1) (60 1))      )
)

(deftemplate recorte
        0 100
        (       (nulo    (0 1) (10 1) (30 0))
                (suave  (10 0) (30 1) (50 0))
                (medio  (30 0) (50 1) (70 0))
                (fuerte  (50 0) (70 1) (100 1))    )
)

; ---------------------- BASE DE REGLAS ------------------------------

; R1: mucho deslizamiento con la moto muy tumbada -> riesgo de highside
(defrule regla_1
        (deslizamiento alto)
        (inclinacion alta)
=>
        (assert (recorte fuerte))
)

; R2: mucho deslizamiento pero moto vertical -> deriva controlable
(defrule regla_2
        (deslizamiento alto)
        (inclinacion baja)
=>
        (assert (recorte medio))
)

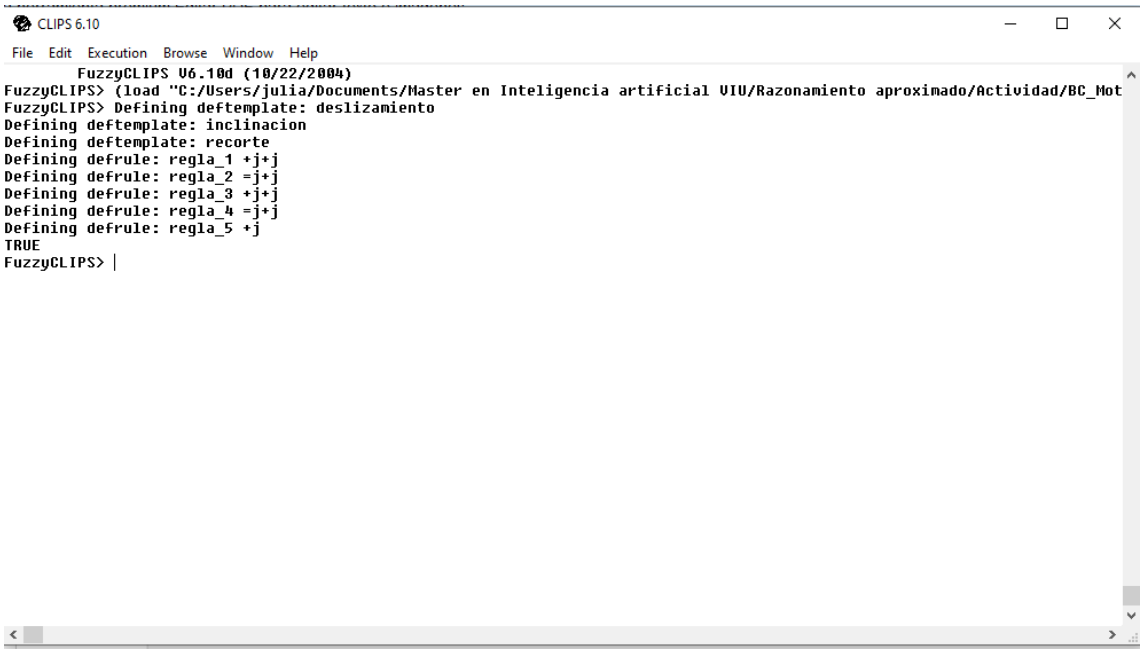
; R3: deslizamiento moderado con la moto tumbada -> poca huella disponible
(defrule regla_3
        (deslizamiento medio)
        (inclinacion alta)
=>
        (assert (recorte medio))
)

; R4: deslizamiento moderado a media inclinacion -> correccion fina
(defrule regla_4
        (deslizamiento medio)
        (inclinacion media)
```

```
=>
        (assert (recorte suave))
)

; R5: sin deslizamiento -> no intervenir (no mira la inclinacion)
(defrule regla_5
        (deslizamiento bajo)
=>
        (assert (recorte nulo))
)
```

Se carga la base de conocimientos en FuzzyCLIPS V6.10d. El programa define los tres *deftemplates* correspondientes a las variables lingüísticas (deslizamiento, inclinación, recorte) y las cinco reglas de producción. El valor TRUE final confirma que la carga se ha completado sin errores:



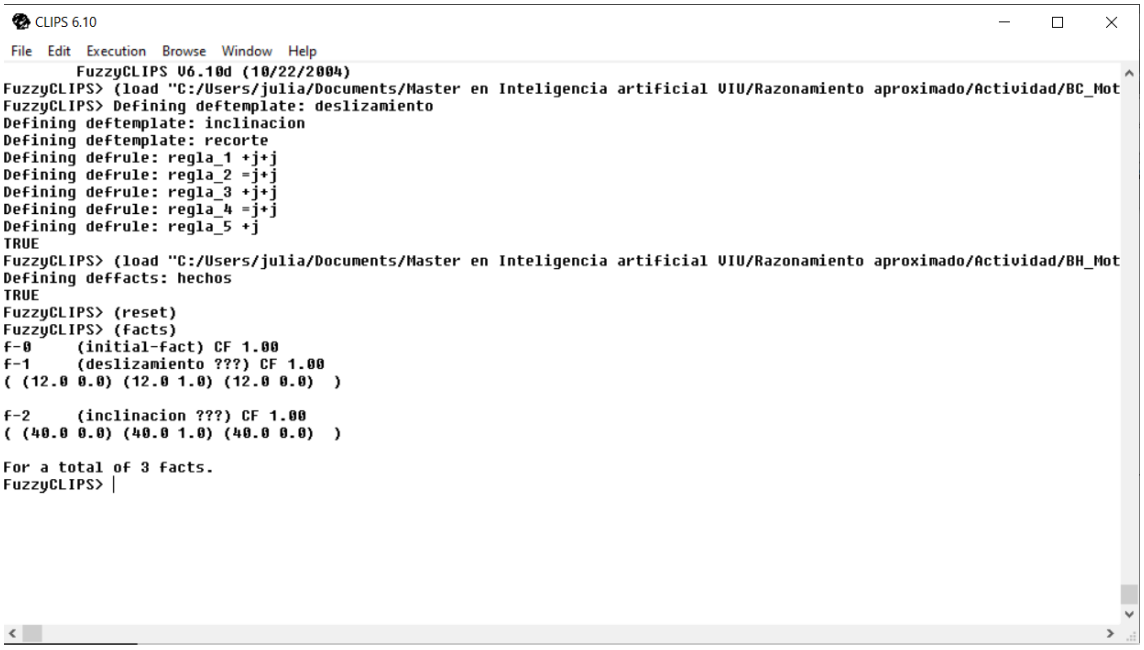
5.2. Base de hechos

Los valores medidos se introducen como *singletons*, igual que en el ejemplo de los aviones visto en clase:

```
; BASE DE HECHOS - Control de traccion predictivo MotoGP
; Julian Samblas Caballero
; Caso de estudio: deslizamiento 12 % con la moto tumbada 40 grados

(deffacts hechos
        (deslizamiento (12 0) (12 1) (12 0))
        (inclinacion   (40 0) (40 1) (40 0))
)
```

Inserción de los hechos en la memoria de trabajo tras ejecutar (reset). Los hechos f-1 y f-2 contienen los valores medidos representados como *singletons*: el conjunto vale 1 únicamente en 12 % y en 40 grados respectivamente. El CF 1.00 indica que la medida se considera completamente cierta, sin incertidumbre asociada al sensor.

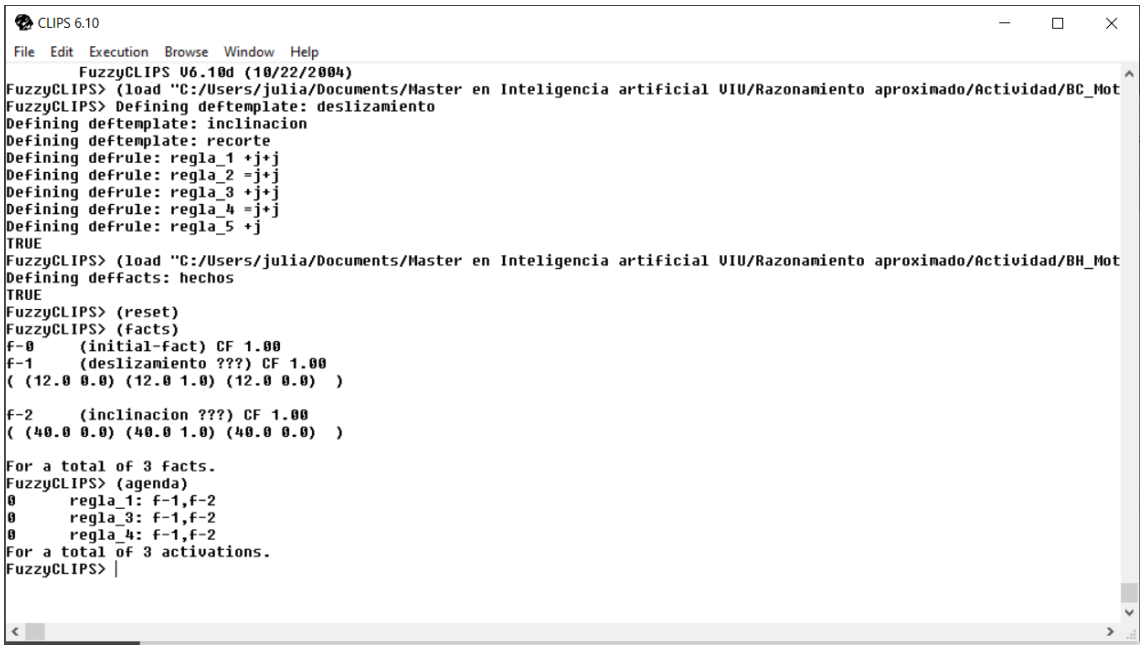


5.3. Ejecución e inferencia tipo Mamdani

Una vez cargadas la base de conocimientos y la base de hechos, el motor de inferencia ya tiene todo lo necesario para razonar. El proceso se realiza en dos fases, que es interesante separar porque se corresponden con el ciclo de reconocimiento y actuación de cualquier sistema de producción.

Primera fase: el conjunto conflicto:

Antes de ejecutar nada, consulto qué reglas han encontrado hechos que encajan con sus premisas: *(agenda)*



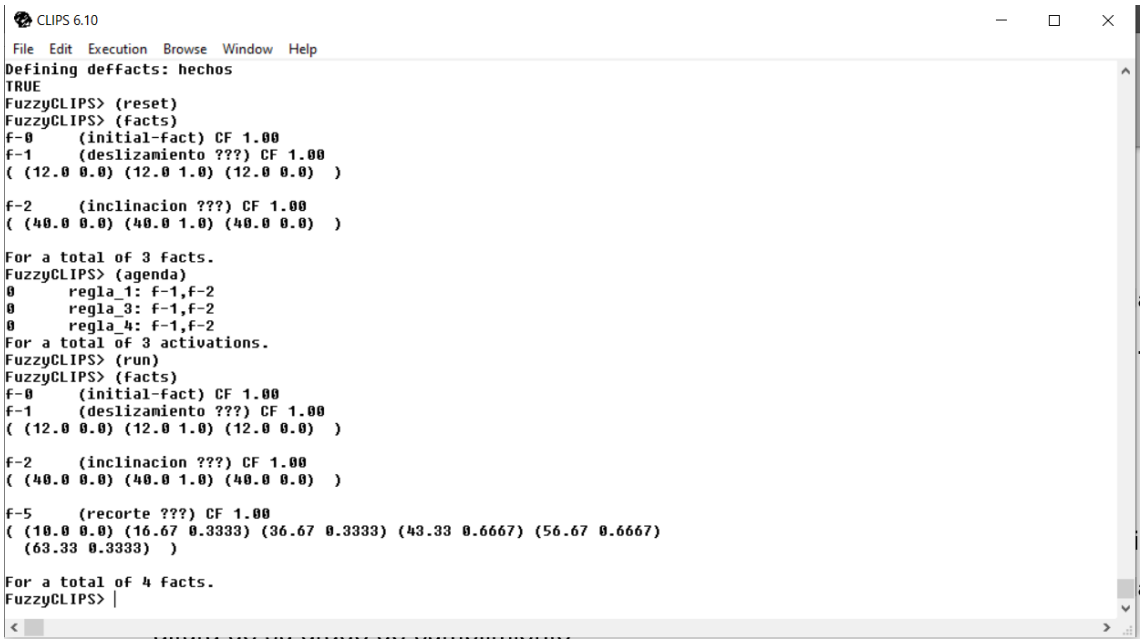
Conjunto conflicto obtenido tras la inserción de los hechos. Se activan las reglas 1, 3 y 4, que son las que tienen un grado de cumplimiento mayor que cero para los valores medidos.

La agenda muestra el conjunto conflicto, es decir, las reglas que están listas para dispararse pero que todavía no se han ejecutado. Es el equivalente a la fase de emparejamiento: el motor ha comparado los hechos de la memoria de trabajo con las premisas de las cinco reglas y ha seleccionado las que se cumplen en algún grado.

Segunda fase: el disparo de las reglas:

(run)

Al ejecutar, el motor dispara las tres reglas activadas. Cada una añade a la memoria de trabajo un hecho borroso sobre la variable de salida, (recorte ???), recortado a la altura de su grado de cumplimiento.

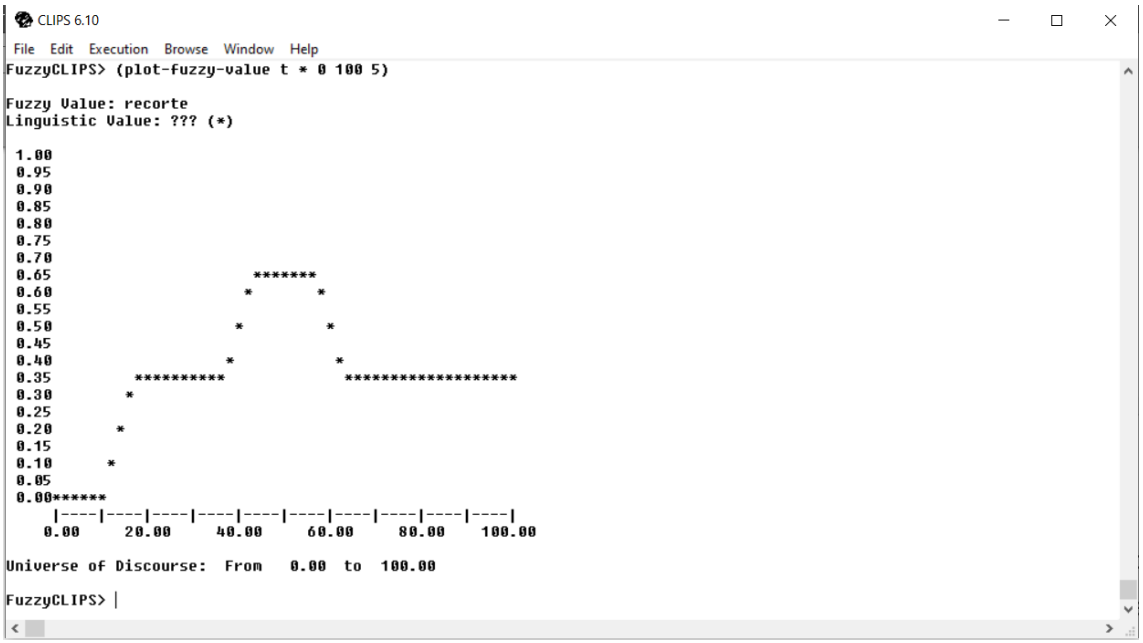


Aquí es donde FuzzyCLIPS aplica el mecanismo de Mamdani sin que haya que programarlo: cuando varias reglas concluyen sobre la misma variable borrosa, el entorno recorta cada consecuente al grado de cumplimiento de su regla y agrega los recortes mediante la unión, es decir, tomando el máximo. Por eso en la memoria de trabajo no quedan tres hechos de salida independientes, sino un único hecho recorte cuyo conjunto borroso combina las tres contribuciones. Es exactamente el mismo procedimiento que se desarrolló paso a paso en el apartado 4, con la diferencia de que aquí lo realiza el motor de inferencia.

5.4. Conjunto borroso resultante

Para visualizar la conclusión antes de desborrosificarla, FuzzyCLIPS permite representar gráficamente cualquier hecho borroso indicando su índice, que en este caso es el 5:

*(plot-fuzzy-value t * 0 100 5)*



Representación del conjunto borroso de salida sobre el universo del discurso de la variable recorte (0 a 100 %). La escalera ascendente corresponde al consecuente "suave" recortado a 0,33, la meseta central al consecuente "medio" recortado a 0,67, y el tramo constante de la derecha al consecuente "fuerte", también recortado a 0,33.

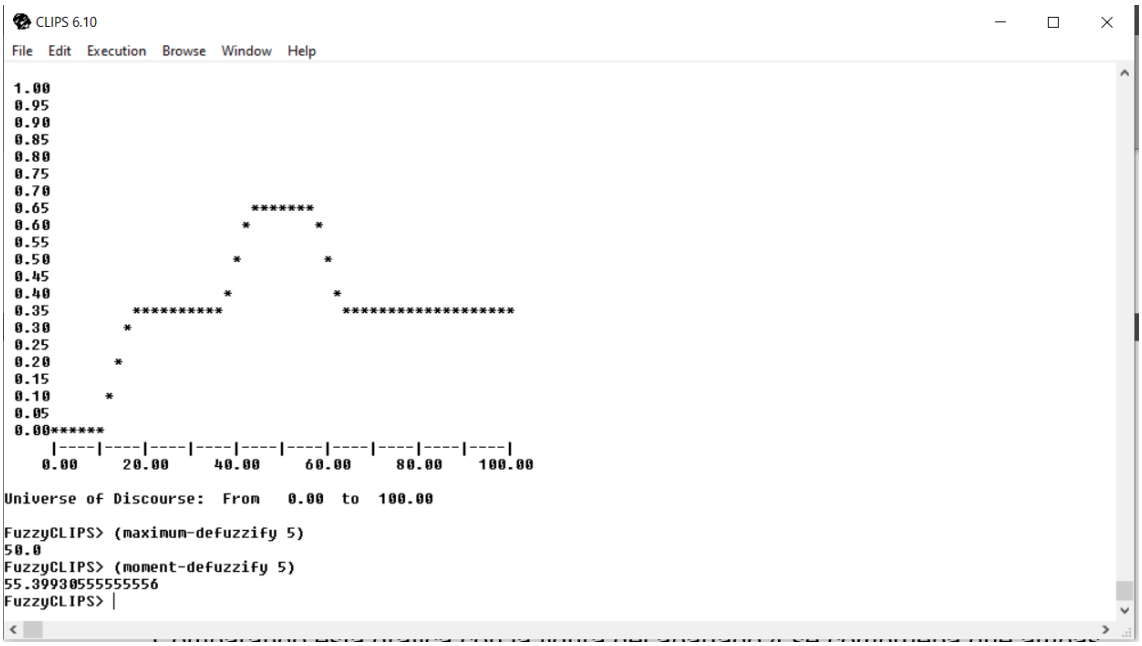
La gráfica confirma punto por punto el conjunto agregado que se obtuvo manualmente en el apartado 4:

- El conjunto arranca en 10 y alcanza el grado 0,33 en torno a 17, que es el recorte de "suave".
- La zona de máximo, con grado 0,67, se extiende aproximadamente entre 43 y 57. Su punto medio es 50, que será el valor que devuelva el criterio de la media del máximo.
- A partir de 63 el conjunto se mantiene constante en 0,33 hasta el final del universo, por la aportación de "fuerte".
- La altura del conjunto es 0,67 y no 1, por lo que el conjunto resultante no está normalizado: ninguna regla se ha cumplido por completo, ya que los valores medidos no coinciden con el pico de ninguna etiqueta. Esta situación es la habitual en un controlador real.

Comparando esta gráfica con la figura del apartado 4 se comprueba que ambas representan el mismo conjunto, obtenido en un caso mediante el cálculo manual representado con Python, y en el otro mediante el motor de inferencia.

5.5. Desborrosificación

El conjunto borroso obtenido no sirve como acción de control, ya que un actuador necesita un valor nítido. FuzzyCLIPS implementa dos de los criterios de desborrosificación estudiados, que se aplican indicando el índice del hecho de salida:



El primer comando aplica el criterio de la **media del máximo**: localiza la zona de máxima pertenencia, que en este caso es la meseta comprendida entre 43,33 y 56,67, y devuelve su punto medio, **50,0 %**.

El segundo aplica el criterio del **centro de gravedad**, denominado *moment* porque calcula el momento del área bajo la función de pertenencia, y devuelve **55,40 %**.

La diferencia entre ambos resultados no es casual y tiene una lectura física. El criterio de la media del máximo solo atiende a la regla dominante, la regla_3, e ignora por completo la contribución de las otras dos. El centro de gravedad, en cambio, pondera las tres reglas según su grado de aplicabilidad, y el resultado se desplaza hacia la derecha porque la regla_1 advierte de un riesgo parcial de pérdida de tracción con la moto tumbada. Es decir, el segundo criterio interviene algo más sobre el motor porque tiene en cuenta ese riesgo, y por eso es el que se ha elegido para el controlador.

5.6. Comparación con el cálculo manual

La siguiente tabla recoge los resultados obtenidos por los dos caminos: el cálculo manual del apartado 4 y la ejecución en FuzzyCLIPS.

Magnitud	Cálculo manual (apartado 4)	FuzzyCLIPS	Diferencia
Reglas activadas	R1, R3 y R4	regla_1, regla_3 y regla_4	ninguna
Grados de cumplimiento	0,33 / 0,67 / 0,33	0,3333 / 0,6667 / 0,3333	ninguna
Zona de máximo	[43,3 ; 56,7]	[43,33 ; 56,67]	ninguna
Media del máximo	50,0 %	50,0 %	0
Centro de gravedad	55,40 %	55,3993 %	< 0,01 %

La coincidencia es total. Los grados de cumplimiento, los vértices del conjunto agregado y los dos valores desborrosificados son los mismos por ambas vías, lo que valida tanto el desarrollo manual del apartado 4 como la implementación del sistema en FuzzyCLIPS.

Conviene señalar que la coincidencia no es trivial: significa que las decisiones de diseño tomadas sobre el papel (el mínimo como t-norma para la conjunción de premisas, el recorte del consecuente por el grado de cumplimiento, la unión por el máximo para agregar y el centro de gravedad para desborrosificar) son exactamente las que implementa el motor de inferencia de FuzzyCLIPS cuando varias reglas concluyen sobre una misma variable borrosa. En otras palabras, el entorno aplica el mecanismo de Mamdani de forma automática, sin necesidad de programar ninguno de esos pasos.

Referencias

- J. Á. Olivas, *Razonamiento Aproximado*, Manual de la asignatura, Máster Universitario en Inteligencia Artificial, Universidad Internacional de Valencia.
- J. Á. Olivas, *Lógica Borrosa y razonamiento aproximado* y *Ejemplo de AVIONES FUZZY-CLIPS*, materiales de clase, VIU.
- L. A. Zadeh, "Fuzzy Sets," *Information and Control*, vol. 8, n.º 3, pp. 338–353, 1965.
- García Cuadra, A. Brunete González y F. Santos Olalla, "Electronic Systems in Competitive Motorcycles: A Systematic Review Following PRISMA Guidelines," *Electronics*, vol. 14, n.º 19, art. 3926, 2025.
- *FuzzyCLIPS Version 6.10d User's Guide*, National Research Council of Canada.

Declaración sobre el uso de herramientas. Las figuras de este trabajo se han generado con un script propio en Python (anexo A), cuya estructura se ha elaborado con la ayuda de una herramienta de IA generativa utilizada como asistente. El diseño del sistema, la definición de los conjuntos borrosos, la base de reglas y el desarrollo de la inferencia son propios. El script se ha empleado únicamente para representar los conjuntos borrosos y verificar los resultados obtenidos analíticamente, que además se han contrastado de forma independiente mediante la implementación en FuzzyCLIPS.

Anexo A. Script de representación en Python

Los conjuntos borrosos se definen igual que en el deftemplate de FuzzyCLIPS: mediante los vértices de su función de pertenencia. La función np.interp interpola linealmente entre esos puntos, que es exactamente lo que hace el entorno al evaluar un valor de entrada.

```
import numpy as np
import matplotlib.pyplot as plt

# Cada conjunto borroso = puntos (x, grado), igual que en FuzzyCLIPS
DESLIZ = {"bajo": ([0, 4, 10], [1, 1, 0]),
          "medio": ([4, 10, 16], [0, 1, 0]),
          "alto": ([10, 16, 20], [0, 1, 1])}
INCLIN = {"baja": ([0, 15, 30], [1, 1, 0]),
          "media": ([15, 30, 45], [0, 1, 0]),
          "alta": ([30, 45, 60], [0, 1, 1])}
RECORTE = {"nulo": ([0, 10, 30], [1, 1, 0]),
           "suave": ([10, 30, 50], [0, 1, 0]),
           "medio": ([30, 50, 70], [0, 1, 0]),
           "fuerte": ([50, 70, 100], [0, 1, 1])}
```

```
def mu(conjunto, x):
    """Grado de pertenencia: interpolacion lineal entre los vertices."""
    xs, ys = conjunto
    return np.interp(x, xs, ys)

# Caso de estudio: deslizamiento 12 %, inclinacion 40 grados
s, l = 12, 40
alfa = {
    "fuerte": min(mu(DESLIZ["alto"], s),  mu(INCLIN["alta"], l)),   # R1
    "medio":  min(mu(DESLIZ["medio"], s), mu(INCLIN["alta"], l)),   # R3
    "suave":  min(mu(DESLIZ["medio"], s), mu(INCLIN["media"], l)),  # R4
}

# Agregacion: maximo de los consecuentes recortados
x = np.linspace(0, 100, 2001)
agregado = np.zeros_like(x)
for etiqueta, a in alfa.items():
    recortado = np.minimum(mu(RECORTE[etiqueta], x), a)
    agregado = np.maximum(agregado, recortado)
    plt.plot(x, recortado, lw=2, label=f"{etiqueta} (alfa={a:.2f})")

# Desborrosificacion por centro de gravedad
cog = np.trapezoid(agregado * x, x) / np.trapezoid(agregado, x)

plt.fill_between(x, agregado, alpha=0.15)
plt.axvline(cog, color="k")
plt.title(f"Centro de gravedad = {cog:.1f} %")
plt.xlabel("recorte de par (%)"); plt.ylabel("grado de pertenencia")
plt.legend(); plt.show()
```